

Plano Aula 14

Markus Stein

25 April 2019

continuação... Estimação \times Predição

- Distribuição **preditiva *a posteriori*** (*versus a priori*): Ver os gráficos abaixo.
 - Qual a influência da distribuição *a priori* $\pi(\theta)$ na distribuição preditiva *a priori* $f_X(x)$? E na distribuição preditiva *a posteriori* $f_{X_{n+1}|X}(x_{n+1})$?
 - E qual a influência da função de verossimilhança na distribuição preditiva *a posteriori* quando $n \rightarrow \infty$?
 - Estimador *plug-in* (abordagem frequentista): $f_X(x_{n+1}; \hat{\theta}_{EMV})$.

Estimadores pontuais Bayesianos (Apostila Prof. Paulo Justiniano, Capítulo 5)

“Uma função perda d , $d(a, \theta)$, representa a perda decorrente de se adotar a ação a quando o verdadeiro estado da natureza é θ .”

- Definição (**Função perda**): Seja $d(a, \theta) \in \mathbb{R}$ uma função tal que:
 - $d(a, \theta) \geq 0$;
 - $d(a, \theta) = 0$ se $a = \theta$;
 então chamaremos d de função perda.
- Estimadores Bayesianos** -> Minimizam a perda esperada $E[d(a, \theta)] = \int_{\Theta} d(a, \theta) \pi(\theta | \mathbf{X}) d\theta$;

Resumo:

Função perda	$d(a, \theta)$	Estimador Bayesiano
Quadrática	$(a - \theta)^2$	$E(\theta \mathbf{X})$
Absoluta	$ a - \theta $	$Med(\theta \mathbf{X})$
Zero-um	$I(a - \theta > \epsilon)$ para um $\epsilon > 0$	$Mod(\theta \mathbf{X})$

- Máxima verossimilhança generalizada** (Notas de Aula, Definição 2.11);
- Estimador de Bayes** (Notas de Aula, Definição 2.12);
- Propriedade de **invariância** do estimador de Bayes? (Bolfarine e Sandoval, pg. 64).

Tarefa 1: Resolver listas suplementares.

Tarefa 2: Trazer dúvidas para a próxima aula.

Os gráficos abaixo comparam todas as distribuições disponíveis para X_1, \dots, X_n da *Bernoulli*(p) (ou X da *Binomial*(n, p)) com *priori* *Beta*(α, β) em três situações:

1. Amostragem de tamanho $n = 10$ da distribuição *Bernoulli*(p) e distribuição *a priori* *Beta*(1,1).
Suponha que estamos interessados em prever a probabilidade de $m = 10$ novas observações.

```
library(LearnBayes)
library(VGAM)


## Loading required package: stats4
## Loading required package: splines

##
## Attaching package: 'VGAM'

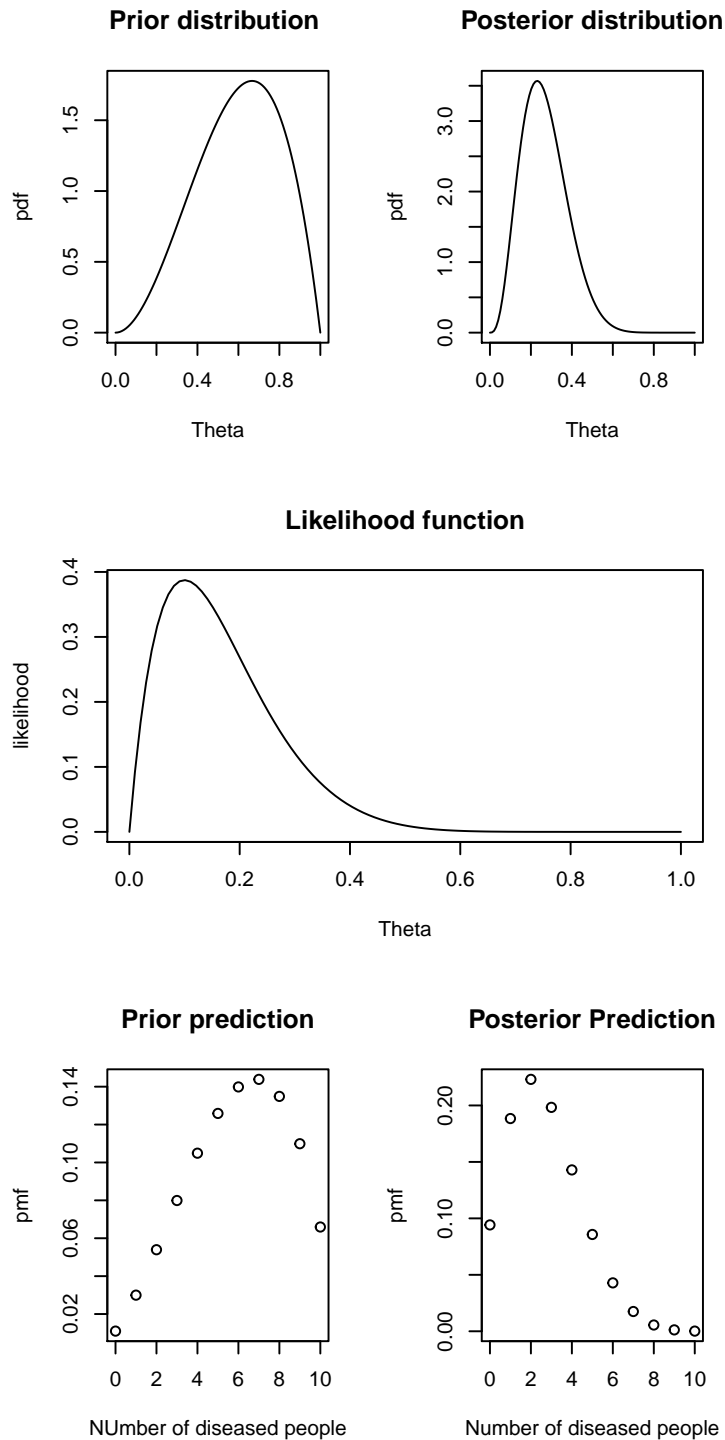
## The following object is masked from 'package:LearnBayes':
##
##      laplace

##### prior parameters
a <- 1
b <- 1
#### Data
n <- 10
x <- 1
##### Prior Distribution
theta <- seq(0, 1, length = 100)
hx <- dbeta(theta, a,b)
layout(matrix(c(1,2,3,3,4,5), 3, 2, byrow = TRUE))
plot(theta, hx, type = "l", xlab = "Theta", ylab = "pdf",
main = "Prior distribution ")
##### Posterior distribution
post <- dbeta(theta, a+x, b+n-x)
plot(theta, post, type = "l", xlab="Theta", ylab="pdf",
main="Posterior distribution")
### Likelihood Function
likelihood<-choose(n,x)*theta^(x)*(1-theta)^(n-x)
plot(theta, likelihood, type="l", xlab="Theta", ylab="likelihood",
main="Likelihood function")
##### Prior Predictive
prior.pred <- 1
m <- 10
y <- 0:m
for (i in 1:(m+1)){
prior.pred[i] = dbetabinom.ab(y[i], m, a,b)
}
plot(y, prior.pred, xlab="Number of diseased people", ylab="pmf",
main="Prior prediction")
##### Posterior Predictive
pos.pred <- 1
y <- 0:m
m <- 10
for (i in 1:(m+1)){
pos.pred[i] = dbetabinom.ab(y[i], m, x+a,b+n-x)
}
plot(y, pos.pred, xlab="Number of diseased people", ylab="pmf",
```

```
main="Posterior Prediction")
```



2. Amostragem de tamanho $n = 10$ da distribuição $Bernoulli(p)$ e distribuição *a priori* $Beta(3, 2)$. Suponha que estamos interessados em prever a probabilidade de $m = 10$ novas observações.



3. Amostragem de tamanho $n = 100$ da distribuição $Bernoulli(p)$ e distribuição *a priori* $Beta(3, 2)$. Suponha que estamos interessados em prever a probabilidade de $m = 100$ novas observações.

