

# Plano Aula 18

Markus Stein

09 May 2019

## *Statistical Learning* = Inferência Estatística?

(Conectar com o exercício 1 da aula passada)

- **Supervisionado:** interesse em explicar o valor observado  $y$  de uma **variável resposta** através da mensuração de uma **variável preditora**  $x$  (ou um vetor  $\mathbf{x}$ ). Exemplo Modelos Lineares.
  - Exemplo:  $Y = f(X) + \epsilon$ , onde
    - \*  $Y$  é variável chamada resposta;
    - \*  $X$  é uma variável preditora;
    - \*  $\epsilon$  é termo (erro) aleatório tal que  $E(\epsilon) = 0$  e  $Var(\epsilon) = \sigma^2$ .
  - Como estimar  $f$ ? se  $\epsilon \sim Normal(\mu, \sigma^2)$  então  $f(X) = \mu$ , Basta estimar  $\mu$ .
- **Não supervisionado:** não possui variável resposta  $Y$  definida. Exemplo problemas de classificação.
- Predição  $\times$  estimação em **aprendizado estatístico**?
  - Estimar  $f$  e saber qual **preditor** influencia a **resposta**? Como é a relação entre cada **preditor** e **resposta**?
  - Predizer  $Y$  através de um  $\hat{Y}$  que minimize  $E[(Y - \hat{Y})^2]$ , por exemplo.
  - *trade-off* entre **interpretação do modelo** e **precisão da predição**.

## Família exponencial

- Definição 1: (**Família Exponencial Unidimensional**) (Bolfarine e Sandoval, definição 2.4.1, pg. 25) Dizemos que a distribuição da variável aleatória  $X$ , com f.m.p ou f.d.p. dada por  $f(x; \theta)$ , pertence à família exponencial unidimensional, se pudermos escrever  $f$  como

$$f(x; \theta) = e^{c(\theta) T(x) + d(\theta) + S(x)} I_A(x),$$

onde

- $c(\cdot)$  e  $d(\cdot)$  são funções reais de  $\theta$ ;
- $T(\cdot)$  e  $S(\cdot)$  são funções reais de  $x$ ;
- $A$  não depende de  $\theta$ .

Exercício 1: Verificar qual(is) das seguintes distribuições pertence(m) à família exponencial. i)  $X \sim Bernoulli(\theta)$ ,  $X \sim Normal(\mu, 1)$ ,  $X \sim Uniforme(0, \theta)$ .

- Teorema 1: Família exponencial **unidimensional** para uma **amostra aleatória**  $X_1, \dots, X_n$  de  $X$ . (Bolfarine e Sandoval, teorema 2.4.1). Provar!!!

- Definição 2: (**Família Exponencial  $k$  Dimensional** (Bolfarine e Sandoval, definição 2.4.2, pg. 27)  
Dizemos que a distribuição da variável aleatória  $X$ , com f.m.p ou f.d.p. dada por  $f(x; \theta)$ , pertence à família exponencial  $k$  dimensional, se pudermos escrever  $f$  como

$$f(x; \theta) = e^{\sum_{j=1}^k c_j(\theta) T_j(x) + d(\theta) + S(x)} I_A(x).$$

- Teorema 2: Família exponencial  $k$  **dimensional** para uma **amostra aleatória** (Notas de Aula, definição 2.13, pg. 37). Provar!!!

## Informação de Fisher na Família Exponencial

Teorema 3: Seja  $X$  uma variável aleatória tal que sua f.d.p. ou f.m.p.  $f(x; \theta)$  pertence à família exponencial, e a **informação individual de Fisher** dada por

$$I_1(\theta) = E \left\{ \left[ \frac{\partial}{\partial \theta} \log f(X; \theta) \right]^2 \right\},$$

então vale a **igualdade da informação**

$$E \left\{ \left[ \frac{\partial}{\partial \theta} \log f(X; \theta) \right]^2 \right\} = -E \left[ \frac{\partial^2}{\partial \theta^2} \log f(X; \theta) \right]$$

Provar!!!

---

**Tarefa 1:** Fazer os exercícios acima e provar os teoremas.

**Tarefa 2:** Ler os “Slides\_aula13” para a próxima aula.

---